WHITEPAPER DE ARQUITETURA & FINOPS | PROCEDI TECNOLOGIA

Diagnóstico de Infraestrutura, Custos & Provedores

Análise de desempenho, blindagem financeira e estratégia de hospedagem para lançamento

Data: Novembro de 2026 | Status: Versão Final Executiva | Público: Sócios e Diretoria

---

SUMÁRIO EXECUTIVO (RESUMO EM 1 MINUTO)

- Causa do susto de R$ 80: O Google Cloud Run (Serverless) cobra por tempo de requisição aberta. O SSE (sincronização de abas) mantém o canal aberto por horas seguidas, mantendo o taxímetro de CPU do Google faturando sem parar.
- O que manter: Netlify no Frontend (R$ 0), Supabase Pro no Banco de Dados ($20 / ~R$ 110) e Buckets para fotos (centavos).
- O que mudar: Migrar o container Spring Boot do Cloud Run para uma Máquina Virtual (Compute Engine / VM) em São Paulo.
- Custo total previsível da operação: R$ 180 a R$ 200 por mês no total, independente da quantidade de abas abertas simultâneas.

1. Por que Apenas 1 Pessoa Gastou R$ 80 nos Testes?

Em requisições normais de API (REST), cada clique dura 0,05 segundos e o servidor desliga imediatamente (centavos/mês). No SSE (múltiplos dispositivos), a conexão permanece aberta por horas para que médicos e recepção recebam eventos em tempo real. No Cloud Run, isso gera faturamento contínuo de CPU.

Critério	Google Cloud Run (Atual)	Compute Engine / VM Fixa (Recomendado)
Modelo Financeiro	Por segundo de requisição aberta	Preço fixo de aluguel mensal
Comportamento com SSE	Taxímetro roda sem parar enquanto a aba estiver aberta	Conexões usam RAM já contratada (R$ 0 extra)
1 pessoa testando	Pode gerar R$ 80 se esquecer aba aberta	Exatamente o valor fixo contratado (~R$ 80)
30 pessoas conectadas	Risco de faturas acima de R$ 500 no mês	Exatamente os mesmos R$ 80 fixos
Previsibilidade de Fatura	Baixa (risco de sustos operacionais)	100% Previsível e travada

2. O Fator Latência: Por que Datacenter em São Paulo é Mandatório

No Render gratuito (EUA), o sistema levava até 2 minutos para abrir e 20s por clique por causa da hibernação (cold start) e do efeito ping-pong transcontinental (15.000 km entre o usuário em SP, o servidor nos EUA e o Supabase em SP). No Google Cloud em São Paulo (southamerica-east1), a latência é de 15ms a 35ms. Todo provedor de backend do Procedi deve estar obrigatoriamente em São Paulo.

3. Matriz da Stack Completa & Custo Mensal Previsto

Camada	Provedor Atual	Decisão	Custo Previsto	Justificativa
Frontend SPA	Netlify	MANTER	R$ 0,00	React 19 em CDN global rápida a custo zero.
Banco & Auth	Supabase Pro	MANTER	$20 (~R$ 110)	PostgreSQL gerenciado com backups diários e auth pronta.
Fotos/Arquivos	GCS / R2	MANTER	Centavos (~R$ 3)	Buckets são extremamente baratos. Nunca salve fotos na VM.
Backend & SSE	Google Cloud Run	MUDAR P/ VM	R$ 75 a R$ 90	VM fixa no Google Cloud SP. Elimina sustos de fatura com SSE.

CUSTO TOTAL FIXO PREVISTO DA OPERAÇÃO: **~R$ 180 a R$ 200 / mês (100% Previsível)**

4. Decisão de Produto & Checklist de Execução

- Precificação: NÃO limite o tempo real no plano mais caro. O custo na VM é zero centavos adicionais. Cobrem por médicos/assentos.
- Passo 1 (Imediato no Cloud Run): Trave Concurrency = 80 e Max Instances = 1. Ative alerta no Google Billing para R$ 40/mês.
- Passo 2 (Pré-lançamento): No mesmo Google Cloud, suba uma VM Compute Engine (e2-small em SP) e rode o Docker do Spring Boot.
- Passo 3 (Go-to-market): Lance comercialmente com stack estável, latência instantânea e custos mensais 100% sob controle.